BÁO CÁO QUÁ TRÌNH THỰC HIỆN LAB02 - NHÓM 4

1. TỔNG QUAN.

- Bài thực hành Lab02 xây dựng 1 quy trình xử lý và quản lý dữ liệu nghiên cứu có thể kiểm chứng, từ tiếp nhận dữ liệu đầu vào, đánh giá chất lượng, chuẩn hoá dữ liệu đến quản lý metadata và kiểm soát phát hành.
- Dữ liệu đầu vào gồm các tệp có định dạng CSV và JSONL, cùng dữ liệu tham chiếu phục vụ kiểm tra chất lượng. Nhóm sử dụng Data Contract để xác định các quy tắc xử lý và tiêu chí đánh giá.
- Quá trình thực hiện được chia thành 5 nhiệm vụ chính:
  1. Kiểm tra đầu vào và tính toàn vẹn.
  2. Đánh giá chất lượng
  3. Chuẩn hoá, khử trùng lặp và cách ly.
  4. Vận hành metadata và lineage.
  5. Kiểm soát phát hành dữ liệu.

2. PHƯƠNG PHÁP THỰC HIỆN.

- Nhóm triển khai theo từng giai đoạn, lưu mã nguồn và kết quả kiểm thử trong repository để có thể đối chiếu và tái thực hiện. Quy trình tổng quát:
  kiểm kê đầu vào → xác minh tính toàn vẹn → đánh giá chất lượng ban đầu → chuẩn hóa và phân loại dữ liệu → đối soát đầu ra → hoàn thiện metadata → kiểm soát phát hành.
- Các công cụ chính gồm **Python** để xây dựng chương trình xử lý và kiểm thử; **DuckDB/SQL** để truy vấn và tính chỉ số; **JSON/JSONL** để lưu kết quả có cấu trúc; **CSV và Parquet** để lưu dữ liệu; **SHA-256** để xác minh tính toàn vẹn; **Git/GitHub** để quản lý mã nguồn.
- Sau mỗi giai đoạn, nhóm lưu các tệp evidence tương ứng. Cách làm này giúp phân biệt dữ liệu đầu vào, dữ liệu ứng viên và dữ liệu bị cách ly, đồng thời hỗ trợ kiểm tra lại kết quả thay vì chỉ dựa vào thao tác thủ công.

3. CÁC BƯỚC THỰC HIỆN.

3.1. Task1 - Input Freeze, Integrity and Contract.

- Task 1 tập trung xác định bộ dữ liệu đầu vào, ghi nhận thông tin các tệp và xây dựng hợp đồng dữ liệu trước khi thực hiện xử lý. Nhóm kiểm tra các đối tượng trong bucket research-raw, tại tiền tố lab2/inputs/batch-01/, và so sánh dung lượng cùng SHA-256 thực tế với giá trị mong đợi.

Tệp dữ liệu	Dung lượng (Byte)	Kết quả
observations_a.csv	421.028	**PASS**
observations_b.jsonl	1.037.439	**PASS**
qa_reference.csv	1.423	**PASS**
sensors.csv	256	**PASS**

- Theo I01.json, cả bốn đối tượng đều có dung lượng và SHA-256 khớp với thông tin đã xác định. I02.json ghi nhận 5.000 bản ghi trong observations_a.csv và 5.205 bản ghi trong observations_b.jsonl, tổng cộng 10.205 envelopes; có 10.205 khóa vật lý duy nhất và 5 dòng JSONL sai định dạng được bảo toàn.
- Nhóm dùng integrity_test.py để thay đổi một byte trong bản sao thử nghiệm của observations_a.csv rồi tính lại SHA-256. Hash ban đầu là 5157418915d867980fac8d84551a8b856bba1669ca2e33cef91a15ee82101aea; hash sau thay đổi là abf16694706a4c8def6a7473a6fd14647309f5d8a4a52b70e2f4c59d245d4e7a. Chương trình phát hiện thay đổi, trong khi bản gốc không bị sửa; kết quả I03 là LOCAL-PASS.
- Hợp đồng contracts/contract.json sử dụng phiên bản research-telemetry-v1, quy định định dạng, phạm vi nhiệt độ hợp lệ từ -30°C đến 60°C, ngưỡng dữ liệu đến muộn 900 giây, khóa nghiệp vụ record_id và quy tắc chọn bản ghi khi trùng lặp.
- Nhóm còn kiểm tra quyền truy cập của principal ingestor. Bằng chứng trước điều chỉnh ghi nhận thao tác ghi vào research-release thành công ngoài mong muốn. Sau điều chỉnh, access-test.json cho thấy ingestor đọc research-raw thành công (HTTP 200), nhưng thao tác ghi research-release bị từ chối (HTTP 403 AccessDenied).

  → Kết quả Task 1: hoàn thành kiểm kê đầu vào, kiểm tra hash, kiểm thử phát hiện thay đổi và xác minh lại quyền ghi theo bucket.

3.2. Task 2 - Data Quality Assessment.

- Task 2 đánh giá chất lượng dữ liệu ban đầu bằng các chỉ số định lượng. Nhóm sử dụng DuckDB, Python và SQL để chuẩn bị dữ liệu, kiểm tra kiểu dữ liệu và tính toán các chỉ số theo hợp đồng. Kết quả được lưu trong task2-quality/ quality_before.json.
- Mốc AS_OF được cố định tại 2026-02-09T00:00:00Z. Báo cáo chất lượng ghi nhận 10.205 envelopes đầu vào; 5 lỗi phân tích cú pháp; 40 bản ghi bị loại ở bước kiểm tra khóa; 10.160 bản ghi đủ điều kiện kiểm tra khóa; 9.960 bản ghi thắng sau khử trùng lặp và 200 bản ghi trùng lặp bị thay thế.

Chỉ số	Kết quả ban đầu	Ngưỡng	Trạng thái
Q_REQUIRED	9.850/9.960 ≈ 98,90%	100%	**FAIL**
Q_UNIQUE_KEY	9.960/10.160 ≈ 98,03%	100%	**FAIL**
Q_VALUE	9.710/9.960 ≈ 97,49%	100%	**FAIL**
Q_REGISTRY	9.930/9.960 ≈ 99,70%	100%	**FAIL**
Q_CHRONO	9.890/9.960 ≈ 99,30%	100%	**FAIL**
Q_TIMELY	9.690/9.890 ≈ 97,98%	95%	**PASS**
Q_QA_AGREEMENT	95/100 = 95%	95%	**PASS**
Q_QA_COVERAGE	100/100 = 100%	100%	**PASS**

- Các chỉ số được tính trên những nhóm bản ghi tương ứng, do đó mẫu số có thể khác nhau. Kết quả cho thấy dữ liệu ban đầu còn vấn đề về trường bắt buộc, tính duy nhất của khóa, giá trị đo, tính nhất quán với danh mục cảm biến và thứ tự thời gian. Hai chỉ số liên quan dữ liệu tham chiếu QA đạt ngưỡng, trong khi các chỉ số chất lượng cốt lõi cần được xử lý ở Task 3.

  → Kết quả Task 2: tạo được báo cáo chất lượng ban đầu có số liệu định lượng, làm căn cứ cho các bước chuẩn hóa và lọc dữ liệu tiếp theo.

3.3. Task 3 - Normalization, Deduplication and Quarantine.

- Task 3 xử lý các vấn đề chất lượng được phát hiện ở Task 2. Nhóm sử dụng chương trình Python và câu lệnh SQL để kiểm tra hợp đồng, chuẩn hóa dữ liệu, xác định bản ghi đủ điều kiện, khử trùng lặp và phân loại bản ghi không hợp lệ.
- Đối với các bản ghi có cùng record_id, quy tắc lựa chọn trong hợp đồng được sử dụng để xác định bản ghi giữ lại. Các bản ghi trùng lặp được ghi riêng; các bản ghi bị loại khỏi tập ứng viên được đưa vào quarantine để bảo toàn dấu vết và hỗ trợ điều tra nguyên nhân.

Tệp đầu ra	Vai trò	Số bản ghi
curated.parquet	Tập dữ liệu ứng viên đã xử lý	9610
quarantine.csv	Bản ghi bị cách ly	395
duplicates.csv	Bản ghi bị trùng lặp	200

- Theo reconciliation.json, tổng đầu vào là 10.205 bản ghi. Phép đối soát cho kết quả 10.205 = 9.610 + 395 + 200 và trường reconciled có giá trị true. Tệp bằng chứng cũng lưu hash của đầu vào, hợp đồng và chương trình xử lý.
- Nhóm kiểm tra khả năng tái lập kết quả khử trùng lặp bằng cách thay đổi thứ tự đầu vào. Bằng chứng c02_dedup_replay.json ghi nhận các hash của tập bản ghi thắng, bản ghi trùng lặp và nhóm cách ly không thay đổi giữa các lần kiểm tra. C05.json xác nhận curated.parquet có 9.610 bản ghi, đúng schema gồm 10 cột: record_id, sensor_id, site, event_time_utc, ingest_time_utc, temperature_c, is_late, source_object, source_row và source_sha256.
- Kết quả quality_after.json ghi nhận các chỉ số chất lượng của tập curated đều đạt ngưỡng: trường bắt buộc đầy đủ 100%; khóa nghiệp vụ duy nhất 100%; giá trị nhiệt độ hợp lệ 100%; tính nhất quán cảm biến 100%; tính hợp lệ thời gian 100%; độ kịp thời khoảng 97,92%, cao hơn ngưỡng 95%; độ bao phủ và mức độ phù hợp QA cũng đạt ngưỡng quy định.

  → Kết quả Task 3: tạo được tập dữ liệu ứng viên, tập cách ly và danh sách trùng lặp; hoàn thành đối soát số lượng, kiểm tra schema, kiểm tra tính ổn định của kết quả khử trùng lặp và đánh giá chất lượng sau xử lý.

3.4. Task 4 - Make Metadata Operational.

- Task 4 xây dựng metadata phục vụ tra cứu, truy nguồn gốc và quản lý vòng đời dữ liệu
- Xây dựng danh mục metadata: Nhóm sử dụng generate_catalod_and_queries.py để tạo task4/ catalog.json, mô tả 3 nhóm dữ liệu:

Dataset	Nội dung	Phân loại
raw-observations	Dữ liệu quan sát gốc	**RESTRICTED**
quarantine-collection	Các bản ghi không đáp ứng điều kiện xử lý	**RESTRICTED**
curated-candidate	Dữ liệu đã chuẩn hóa, khử lặp	**INTERNAL**

- Truy vấn metadata và lineage:
  - Nhóm tạo 3 bằng chứng M01_result.json, M02_result.json và M03_consumer _answers.json để kiểm tra khả năng tra cứu thông tin, phân loại, chính sách lưu giữ và hướng dẫn người dùng.
  - Chương trình generate_lineage_and_traces.py tạo các sự kiện curate_start.json, curate_complete.json cùng 2 tệp truy nguyên L02_trace_accpted.json và

L03_trace_quarantine.json. Những tệp này ghi đầu vào và ra, minh họa cách truy ngược nguồn gốc các bản ghi được chấp nhận/ cách ly.

- Chính sách dữ liệu: Nhóm sử dụng generate_retention.py để tạo retention -plan.json quy định thời hạn lưu giữ cho từng nhóm dữ liệu:
  - Dữ liệu gốc: 30 ngày
  - Dữ liệu cách ly: 7 ngày
  - Dữ liệu phát hành: 90 ngày.

→ Kết quả task4: Đã xây dựng danh mục metadata, các truy vấn kiểm tra, sự kiện lineage, bằng chứng truy nguyên và kế hoạch lưu giữ dữ liệu.

3.5. Task 5 - Release Gate and Controlled Data Release.

Task 5 xây dựng cơ chế kiểm tra điều kiện phát hành, phê duyệt và xác minh tính toàn vẹn của dữ liệu.

- Kiểm thử điều kiện phát hành: Nhóm sử dụng task5/ scripts/ run_mutation_probes.py để kiểm tra 8 trường hợp thay đổi dữ liệu hoặc metadata. Kết quả được lưu trong probes_results.json.

Mã phép thử	Nội dung kiểm tra	Kết quả
P01	Dữ liệu ứng viên không bị thay đổi	**PASS**
P02	Đưa nhiệt độ lên 100C	**Bị từ chối**
P03	Đặt trường nhiệt độ thành NULL	**Bị từ chối**
P04	Thêm bản ghi trùng	**Bị từ chối**
P05	Xoá thông tin steward	**Bị từ chối**
P06	Thay đổi hash đầu vào	**Bị từ chối**
P07	Xoá thông tin đầu ra trong lineage	**Bị từ chối**
P08	Xoá mã mẫu QA	**Bị từ chối**

→ 8 phép thử đều có trạng thái MATCH, cho thấy kết quả thực tế khớp với kết quả mong đợi.

- Phê duyệt và phát hành dữ liệu:
  - Tệp sidecar_review.json ghi nhận quyết định APPROVED của người rà soát dữ liệu, liên kết với mã lần chạy và SHA-256 của tập dữ liệu ứng viên
  - Nhóm sử dụng publish_and_verify.py để đóng gói curated.parquet, catalog.json và quality_after.json vào task5/release/. Chương trình tạo release_manifest.json

với mã phát hành REL-2026-V1.0, thông tin phe duyệt, số lượng bản ghi và các giá trị hash phục vụ xác minh.
- Consumer_verification.json ghi nhận kết quả kiểm tra hash, số lượng 9610 bản ghi và quyền truy cập dữ liệu phía người dùng.

→ Kết quả task 5: Đã thực hiện kiểm thử điều kiện phát hành, ghi nhận phê duyệt, tạo manifest và lưu bằng chứng xác minh bản phát hành.

4. KẾT QUẢ CUỐI CÙNG.

- Nhóm đã triển khai quy trình xử lý dữ liệu qua 5 task, từ kiểm tra đầu vào đến kiểm soát phát hành. Kết quả chính gồm:
  - Tạo tập dữ liệu ứng viên gồm 9610 bản ghi 395 bản ghi cách ly và ghi nhận 200 bản ghi trùng lặp.
  - Xây dựng danh mục metadata, lineage và kế hoạch lưu giữ.
  - Các chỉ số chất lượng sau xử lý đạt ngưỡng theo quality_after.json
  - Kiểm thử điều kiện phát hành, tạo manifest và xác minh tính toàn vẹn dữ liệu
- Mã nguồn và các bằng chứng được lưu trong repository để phục vụ kiểm tra và đối chiếu.

5. PHÂN CÔNG VÀ ĐÓNG GÓP.

Thành viên	Phần phụ trách	Công việc	Đóng góp
Đỗ Đức Kiệt	Task 1	Tạo, triển khai 4 bài kiểm thử I01–I04, xác minh tính toàn vẹn của 4 file dữ liệu bằng SHA-256, bảo đảm khả năng truy vết nguồn gốc dữ liệu	20%
Dương Hải Khôi	Task 2	Đánh giá chất lượng dữ liệu ban đầu bằng các chỉ số định lượng	20%
Mai Quang Diệp	Task 3	Viết lệnh SQL lọc dữ liệu, khử trùng lặp, viết test kiểm tra chất lượng dữ liệu	20%
Phạm Chí Dũng	Task 4	Xây dựng danh mục metadata, lineage và kế hoạch lưu giữ	20%
Đinh Huy Hoàng	Task 5	Tạo 8 mutation probe từ p01 - p08, tạo file release manifest, kiểm tra file curated.parquet với vai trò analyst	20%